

日期:2026/04/28

講者:許正欣

題目:具冒充者與欺騙攻擊偵測之語者辨識

具冒充者與欺騙攻擊偵測 之語者辨識

Speaker Recognition with Countermeasures
against Imposter and Spoofing Attacks

雲林科技大學 資訊工程系

許正欣

2026/4/28

語者辨識系統攻擊方式

- 人聲模仿 Impersonation
- 錄音回放 Replay
- 語音合成 Speech synthesis
- 語音轉換 Voice conversion

語者辨識的兩種類型


- 語者驗證 Speaker verification
- 語者識別 Speaker identification

Text dependent 本文相關

語者必須說固定句子，辨識效果通常較好，但訓練較不容易

Text independent 本文無關

不限制說話內容，使用彈性較高




1. 偵測攻擊階段

語音輸入 → CQCC 特徵抽取 → 二元分類偵測攻擊模型
判斷聲音是真人還是假聲音，是否為偽造或攻擊語音。

2. 語者辨識階段

語音輸入 → MFCC 特徵抽取 → i-vector 特徵抽取 → 分類模型 → 辨識結果



CQCC 語音特徵


結合了 CQT(Constant Q Transform)，並經過倒頻譜處理後得到

語音特徵。

對聲音變化比較敏感，符合人耳聽覺系統，適合用來偵測欺騙攻擊。

常數Q轉換(CQT)

- CQT最初是應用在音樂處理領域，其產生的頻譜特色是：
 - 頻率軸非線性標度 (Linear scale) 而是對數標度 (Log scale)
 - 隨著頻率改變窗口長度也會跟著改變




9

CQT 常數 Q 轉換

- 頻率軸為非線性，使用短時距傅立葉變換
- 一般傅立葉轉換只能得到整體頻率成分，無法呈現頻率隨時間的變化。
- 短時距傅立葉變換雖能分析頻率，但無法完整呈現頻率隨時間的變化。

語音特徵擷取 i-vector

- i-vector是基於聯合因子分析 (Joint Factor Analysis, JFA)方法，主要有下列特點：
 - 通常使用MFCC進行截取
 - 需要非註冊語者語料來建立通用背景模型(Universal Background Model, UBM) 統計語者特徵分佈的模型
 - 將語者特徵進行特徵降維，大幅降低特徵複雜度
 - 使不固定長度的語音特徵變成400維的固定長度



10

i-vector

能夠代表特定說話人語音特徵的低維向量，它將高維度的超向量（Supervector）投影到一個較小的空間。


偵測與辨識的決策方式

系統使用門檻值 threshold 來做判斷

- 欺騙攻擊偵測模型
若小於門檻值將被判定為生成語音，反之判定為真實語音
- 語者辨識模型
若低於門檻值將被判定為仿冒者，反之判定為目標語者

分數正規化

- 分數正規化 (Score Normalization) 是尋找強健門檻值的常用方法：對模型的輸出分數作正規化，使目標語者跟冒充者之間的分數分佈能夠拉開，期望更容易找出適切的門檻值。
- 但此正規化方法無法同時提高目標語者的接受率與冒充者的拒絕率，這是因為目標語者和冒充者的分數分佈會有部分的重疊。



14

分數正規化

- 把模型輸出的分數做標準化，讓目標語者與冒充者的分數分布盡量拉開，讓門檻值更容易設定。
- 目標語者與冒充者的分數分布可能會有重疊，所以無法同時提高。
- 安全性與方便性之間會有取捨。

整體學習

- 把多個分類器整合起來做判斷
- 不同分類器各有優缺點，組合起來可以提升穩定性

此系統採用較嚴格的全數決

- 多數決 Majority voting
多數分類器同意就通過
- 全數決 Unanimity voting
所有分類器都同意才通過

條件式重試機制

解決目標語者被錯誤拒絕的問題，系統加入條件式重試機制
Conditional Retry

- 欺騙攻擊偵測模型

可以改用 RNN 循環神經網路，解決語音輸入長度不一致的問題。

- 語者辨識模型

可以再做整體學習的超參數最佳化，降低模型複雜度，並改善系統效能。